

รายงานกระบวนการทำงาน (Process Report)

การวิเคราะห์ประสิทธิภาพกระบวนการยุติธรรมระดับเขตในอินเดียด้วยเทคนิคการจัดกลุ่ม K-Means และการจำแนกประเภทด้วยจำลองตัดสินใจ

District-Level Judicial Efficiency Analysis in India Using K-Means Clustering and Decision Tree

ชุดข้อมูล Indian Crimes Dataset | ค.ศ. 2014-2023

1. ข้อมูลกลุ่ม สมาชิก และบทบาท

สมาชิก	บทบาท	ความรับผิดชอบหลัก
นายคิวัช คนขยัน	Data Analyst / Data Engineer	Data Cleaning, Data Preparation, วิเคราะห์ข้อมูล, สร้างผลโมเดล
นางสาวอัษฎาปริญา งามสวย	Documentation Lead	รายงาน Process Report, สไลด์, บันทึกการประชุม, Contribution Log
นายณัฐพงศ์ ไชยพูน	Visualization	Power BI + Website

2. ภาพรวมชุดข้อมูล

แหล่งข้อมูล: Kaggle – Indian Crimes Dataset โดยไฟล์ที่ใช้ในการทำงานมีจำนวน 30,000 ระเบียบ 10 คอลัมน์ ครอบคลุมข้อมูลอาชญากรรม 12 รัฐ 300 เขต 10 ประเภทอาชญากรรม และช่วงปี ค.ศ. 2014-2023

รายการ	ผลการตรวจสอบ
จำนวนแถว	30,000 แถว
จำนวนคอลัมน์	10 คอลัมน์
ช่วงเวลา	ค.ศ. 2014-2023
จำนวนรัฐ	12 รัฐ
จำนวน District	300 เขต
จำนวนประเภทอาชญากรรม	10 ประเภท
Missing values	0 ค่า
Duplicate rows	0 แถว

3. กระบวนการตาม CRISP-DM

3.1 Business Understanding

กำหนดเป้าหมายเพื่อศึกษารูปแบบและการกระจายของอาชญากรรมในแต่ละพื้นที่และช่วงเวลารวมถึงทดลองจัดกลุ่มข้อมูลที่มีลักษณะใกล้เคียงกัน และนำเสนอผลด้วยการแสดงผลข้อมูลแบบโต้ตอบเพื่อให้ผู้ใช้สามารถสำรวจข้อมูลตามรัฐ เขต ประเภทอาชญากรรม และปีได้ง่ายขึ้น

โจทย์เชิงวิเคราะห์ที่ใช้ในโครงการ ได้แก่

- 1) อาชญากรรมมีการกระจายแตกต่างกันอย่างไรระหว่างประเภทและพื้นที่
- 2) แนวโน้มจำนวนคดีเปลี่ยนแปลงอย่างไรตามเวลา
- 3) พื้นที่/ระเบียนที่มีลักษณะด้านจำนวนคดีอัตราอาชญากรรมและดัชนีกระบวนการยุติธรรมใกล้เคียงกันสามารถจัดเป็นกลุ่มใดได้บ้าง

3.2 Data Understanding

จากการตรวจสอบโครงสร้างข้อมูล พบว่า 3 คอลัมน์เป็นข้อมูลเชิงหมวดหมู่ ได้แก่ State, District และ Crime_Type ส่วนข้อมูลเชิงตัวเลข ได้แก่ Year, Cases_Reported, Chargesheeted, Convictions, Population, Crime_Rate_per_100k และ Justice_index

ตัวแปร	ชนิดข้อมูล	ค่าต่ำสุด	ค่าเฉลี่ย	ค่าสูงสุด
Cases_Reported	Numerical	20	612.15	1200
Chargesheeted	Numerical	13	488.98	1135
Convictions	Numerical	5	268.79	835
Population	Numerical	810709	3,923,672	6937751
Crime_Rate_per_100k	Numerical	0.31	20.86	144.44
Justice_index	Numerical	0.0065	17.4305	93.353

3.3 Data Preparation

การเตรียมข้อมูลเริ่มจากตรวจสอบจำนวนแถวและคอลัมน์ ชนิดข้อมูล ค่าว่าง ข้อมูลซ้ำ และช่วงค่าของตัวแปรสำคัญ ผลการตรวจสอบพบว่าไม่มี Missing Values และไม่มี Duplicate Rows จึงไม่มีการลบแถวออกจากชุดข้อมูล ในขั้นตอนก่อนนำไปทำ K-means ได้เลือกตัวแปรเชิงตัวเลขที่สะท้อนจำนวนคดี ผลของการดำเนินคดี อัตราอาชญากรรม และดัชนีความยุติธรรม

ได้แก่ Cases_Reported, Chargesheeted, Convictions, Crime_Rate_per_100k และ Justice_index แล้วทำ Standardization เพื่อให้ตัวแปรที่มีหน่วยและขนาดต่างกันมีอิทธิพลต่อการจัดกลุ่มอย่างเหมาะสม

Before-After ของการทำความสะอาดข้อมูล

รายการตรวจสอบ	ไฟล์ดิบ	หลังตรวจสอบ/เตรียมข้อมูล
จำนวนแถว	30,000	30,000
จำนวนคอลัมน์	10	10
Missing values	0	0
Duplicate rows	0	0
ชนิดข้อมูล	มีทั้งข้อความและตัวเลข	ตรวจสอบและกำหนดบทบาทตัวแปรตามชนิดข้อมูล
การเตรียมสำหรับ K-means	ค่าต่างหน่วย	Standardization เฉพาะตัวแปรที่ใช้ทำ clustering

ก่อนที่จะทำความสะอาดข้อมูล

	A	B	C	D	E	F	G	H	I	J
	State	District	Year	Crime_Type	Cases_Reported	Chargesheeted	Convictions	Population	Crime_Rate_per_100k	Justice_Index
1	Uttar Pradesh	Lucknow	2014	Murder	580	519	329	6843158	8.48	17.08
2	Uttar Pradesh	Lucknow	2014	Rape	682	553	213	6843158	9.97	11.78
3	Uttar Pradesh	Lucknow	2014	Kidnapping	206	163	92	6843158	3.01	1.50
4	Uttar Pradesh	Lucknow	2014	Theft	555	432	289	6843158	8.11	12.48
5	Uttar Pradesh	Lucknow	2014	Robbery	1068	718	309	6843158	15.61	22.19
6	Uttar Pradesh	Lucknow	2014	Assault	95	81	54	6843158	1.39	0.44
7	Uttar Pradesh	Lucknow	2014	Burglary	332	217	130	6843158	4.85	2.82
8	Uttar Pradesh	Lucknow	2014	Cybercrime	582	434	263	6843158	8.5	11.41
9	Uttar Pradesh	Lucknow	2014	Dowry Deaths	386	319	215	6843158	5.64	6.86
10	Uttar Pradesh	Lucknow	2014	Fraud	523	424	219	6843158	7.64	9.29
11	Uttar Pradesh	Lucknow	2015	Murder	965	794	579	6843158	14.1	45.97
12	Uttar Pradesh	Lucknow	2015	Rape	900	848	506	6843158	13.15	42.91
13	Uttar Pradesh	Lucknow	2015	Kidnapping	1036	786	392	6843158	15.14	30.81
14	Uttar Pradesh	Lucknow	2015	Theft	649	443	187	6843158	9.48	8.28
15	Uttar Pradesh	Lucknow	2015	Robbery	984	643	433	6843158	14.38	27.84
16	Uttar Pradesh	Lucknow	2015	Assault	441	324	186	6843158	6.44	6.03
17	Uttar Pradesh	Lucknow	2015	Burglary	191	127	65	6843158	2.79	0.83
18	Uttar Pradesh	Lucknow	2015	Cybercrime	1045	727	320	6843158	15.27	23.26
19	Uttar Pradesh	Lucknow	2015	Dowry Deaths	713	527	244	6843158	10.42	12.86
20	Uttar Pradesh	Lucknow	2015	Fraud	661	456	163	6843158	9.66	7.43
21	Uttar Pradesh	Lucknow	2016	Murder	190	171	124	6843158	2.78	2.12
22	Uttar Pradesh	Lucknow	2016	Rape	727	663	419	6843158	10.62	27.78
23	Uttar Pradesh	Lucknow	2016	Kidnapping	980	738	344	6843158	14.32	25.39
24	Uttar Pradesh	Lucknow	2016	Theft	81	62	27	6843158	1.18	0.17
25	Uttar Pradesh	Lucknow	2016	Robbery	303	210	141	6843158	4.43	2.96
26	Uttar Pradesh	Lucknow	2016	Assault	851	742	268	6843158	12.44	19.89
27	Uttar Pradesh	Lucknow	2016	Burglary	180	137	55	6843158	2.63	0.75
28	Uttar Pradesh	Lucknow	2016	Cybercrime	920	862	390	6843158	13.44	33.62

หลังทำความสะอาดข้อมูล

	A	B	C	D	E	F	G	H	I	J	K	L
	State	District	Year	Crime_Type	Cases_Reported	Chargesheeted	Chargesheet_Rate	Convictions	Convictions_Rate	Population	Crime_Rate_per_100k	Justice_Index
1	Uttar Pradesh	Lucknow	2014	Murder	580	519	89.48	329	56.72	6843158	8.48	17.08
2	Uttar Pradesh	Lucknow	2014	Rape	682	553	81.09	213	31.23	6843158	9.97	11.78
3	Uttar Pradesh	Lucknow	2014	Kidnapping	206	163	79.13	92	44.66	6843158	3.01	1.50
4	Uttar Pradesh	Lucknow	2014	Theft	555	432	77.84	289	52.07	6843158	8.11	12.48
5	Uttar Pradesh	Lucknow	2014	Robbery	1068	718	67.23	309	28.93	6843158	15.61	22.19
6	Uttar Pradesh	Lucknow	2014	Assault	95	81	85.26	54	56.84	6843158	1.39	0.44
7	Uttar Pradesh	Lucknow	2014	Burglary	332	217	65.36	130	39.16	6843158	4.85	2.82
8	Uttar Pradesh	Lucknow	2014	Cybercrime	582	434	74.57	263	45.19	6843158	8.5	11.41
9	Uttar Pradesh	Lucknow	2014	Dowry Deaths	386	319	82.64	215	55.70	6843158	5.64	6.86
10	Uttar Pradesh	Lucknow	2014	Fraud	523	424	81.07	219	41.87	6843158	7.64	9.29
11	Uttar Pradesh	Lucknow	2015	Murder	965	794	82.28	579	60.00	6843158	14.1	45.97
12	Uttar Pradesh	Lucknow	2015	Rape	900	848	94.22	506	56.22	6843158	13.15	42.91
13	Uttar Pradesh	Lucknow	2015	Kidnapping	1036	786	75.87	392	37.84	6843158	15.14	30.81
14	Uttar Pradesh	Lucknow	2015	Theft	649	443	68.26	187	28.81	6843158	9.48	8.28
15	Uttar Pradesh	Lucknow	2015	Robbery	984	643	65.35	433	44.00	6843158	14.38	27.84
16	Uttar Pradesh	Lucknow	2015	Assault	441	324	73.47	186	42.18	6843158	6.44	6.03
17	Uttar Pradesh	Lucknow	2015	Burglary	191	127	66.49	65	34.03	6843158	2.79	0.83
18	Uttar Pradesh	Lucknow	2015	Cybercrime	1045	727	69.57	320	30.62	6843158	15.27	23.26
19	Uttar Pradesh	Lucknow	2015	Dowry Deaths	713	527	73.91	244	34.22	6843158	10.42	12.86
20	Uttar Pradesh	Lucknow	2015	Fraud	661	456	68.99	163	24.66	6843158	9.66	7.43
21	Uttar Pradesh	Lucknow	2016	Murder	190	171	90.00	124	65.26	6843158	2.78	2.12
22	Uttar Pradesh	Lucknow	2016	Rape	727	663	91.20	419	57.63	6843158	10.62	27.78
23	Uttar Pradesh	Lucknow	2016	Kidnapping	980	738	75.31	344	35.10	6843158	14.32	25.39
24	Uttar Pradesh	Lucknow	2016	Theft	81	62	76.54	27	33.33	6843158	1.18	0.17
25	Uttar Pradesh	Lucknow	2016	Robbery	303	210	69.31	141	46.53	6843158	4.43	2.96
26	Uttar Pradesh	Lucknow	2016	Assault	851	742	87.19	268	31.49	6843158	12.44	19.89
27	Uttar Pradesh	Lucknow	2016	Burglary	180	137	76.11	55	30.56	6843158	2.63	0.75
28	Uttar Pradesh	Lucknow	2016	Cybercrime	920	862	93.70	390	42.39	6843158	13.44	33.62


3.4 Modeling

เลือก K-means Clustering เนื่องจากชุดข้อมูลไม่มีตัวแปรเป้าหมายสำหรับการจำแนกแบบมีผู้สอน และ ใจทย์ต้องการสำรวจกลุ่มข้อมูลที่มีลักษณะคล้ายกัน K-means เหมาะกับข้อมูลตัวเลขที่ผ่านการปรับสเกล และสามารถนำผลกลุ่มไปแสดงบน Dashboard ได้

ตัวแปรที่ใช้ในการจัดกลุ่ม: Cases_Reported, Chargesheeted, Convictions, Crime_Rate_per_100k และ Justice_index ในการทดลองเบื้องต้น ทดสอบ $k = 2-8$ และคำนวณค่า Avg. within-cluster distance (ระยะห่างเฉลี่ยของจุดข้อมูลถึง centroid ของกลุ่มตัวเอง) จากชุดข้อมูลทั้งหมด โดยพิจารณาด้วยวิธี Elbow Method แทนการเลือกจากค่าที่ดีที่สุดจริงๆ เนื่องจากค่า metric นี้มีธรรมชาติดีขึ้นเสมอเมื่อ k เพิ่มขึ้น จึงต้องดูจุดที่อัตราการดีขึ้นเริ่มลดลงอย่างชัดเจนแทน ผลการทดสอบพบว่าอัตราการดีขึ้นลดลงชัดเจนที่สุดหลังจาก $k = 4$ จึงใช้ $k = 4$ เป็นค่าที่เหมาะสมสำหรับการนำเสนอผล ทั้งนี้ควรบันทึกวิธีตั้งค่าให้ตรงกับ process จริงของกลุ่ม

k	Avg. within-cluster distance
2	-2.8273
3	-2.1314
4	-1.7755
5	-1.5736
6	-1.3757
7	-1.2738
8	-1.147

ผลการวิเคราะห์ Elbow Method สำหรับกำหนดจำนวนกลุ่ม K-means



3.5 Evaluation

เลือกจำนวนกลุ่มด้วย Elbow Method โดยดูจากค่า Avg. within-cluster distance ที่ลดลงเรื่อยๆ เมื่อ k เพิ่มขึ้น จุดที่อัตราการลดลงเริ่มคงตัวชัดเจนคือ $k = 4$ จึงเลือกใช้ค่านี้แทนการดูตัวเลขที่ดีที่สุดเพียงอย่างเดียว โดยพิจารณาความหมายของแต่ละกลุ่มและการนำไปใช้แสดงผลประกอบด้วย

การตอบโจทย์วิจัย: ผลการจัดกลุ่มด้วย K-means ($k = 4$) ตอบโจทย์ข้อ 3 ที่ตั้งไว้ในระยะที่ 1 ได้ชัดเจน คือ แบ่งเขต/พื้นที่ออกเป็น 4 กลุ่มตามลักษณะจำนวนคดี อัตราอาชญากรรม และดัชนีกระบวนการยุติธรรมที่ใกล้เคียงกัน ส่วนโจทย์ข้อ 1 และ 2 (การกระจายตามประเภท/พื้นที่ และแนวโน้มตามเวลา) มีคำตอบบางส่วนอยู่แล้วจากขั้นตอน Data Understanding และจะเห็นภาพชัดขึ้นเมื่อนำไปแสดงบน Dashboard ในระยะที่ 6

ข้อจำกัด: จุดหักเห (elbow) บนกราฟ Avg. within-cluster distance ตัดสินด้วยสายตาเป็นหลัก จึงอาจคลาดเคลื่อนได้บ้างหากอัตราการลดลงไม่ชัดเจน นอกจากนี้ K-means ยังตั้งสมมติฐานว่ากลุ่มมีลักษณะเป็นทรงกลม (spherical clusters) ซึ่งอาจไม่ตรงกับรูปแบบข้อมูลจริงทั้งหมด และใช้ตัวแปรเชิงตัวเลขเพียง 5 ตัวในการจัดกลุ่ม ยังไม่ได้รวมมิติเวลาหรือพื้นที่เข้าไปโดยตรง

Insight สำคัญ: ให้สรุปว่าทั้ง 4 กลุ่มมีค่าเฉลี่ยของ Cases_Reported, Chargesheeted, Convictions, Crime_Rate_per_100k และ Justice_index สูงหรือต่ำกว่ากันอย่างไร แล้วเชื่อมโยงกับข้อสรุปเชิงนโยบาย เช่น พื้นที่กลุ่มใดควรได้รับการพัฒนากระบวนการยุติธรรมเพิ่มเติม

3.6 Deployment / Visualization

ผลการวิเคราะห์ถูกออกแบบให้นำเสนอผ่าน Dashboard โดย D3.js เป็นตัวเลือกสำหรับการสร้าง visualization ที่กำหนดรูปแบบและ interaction ได้ละเอียด ส่วน Chart.js ใช้เป็น framework ที่สองสำหรับเปรียบเทียบแนวทางการพัฒนาและความสะดวกในการสร้างกราฟมาตรฐาน

องค์ประกอบ Dashboard ที่เสนอ: ตัวกรอง State, District, Year และ Crime Type; กราฟแนวโน้มตามเวลา; กราฟเปรียบเทียบประเภทอาชญากรรม; แผนภูมิแสดงกลุ่มจาก K-means; และ tooltip สำหรับดูรายละเอียดเมื่อผู้ใช้งานเลื่อนเมาส์

4. เปรียบเทียบ D3.js กับ Chart.js

ตารางที่ 1 ข้อดีและข้อเสียของแต่ละเครื่องมือ


เครื่องมือ	ข้อดี	ข้อเสีย
D3.js v7	+ ควบคุมได้ทุกองค์ประกอบ ออกแบบกราฟรูปแบบใหม่ได้ไม่จำกัด + โลใบรารีเล็ก (~93 KB gzip) และวาดกราฟเร็ว + ปรับรายละเอียดได้ละเอียด เช่น แท่งมนเฉพาะปลาย ช่องว่างระหว่างส่วนของแท่งซ้อน + มีเครื่องมือเฉพาะทาง เช่น projection แผนที่ และการหาจุดที่ใกล้เคียงที่สุด (Delaunay)	- ต้องเขียนเองทุกอย่าง ทั้งแกน tooltip legend แอนิเมชัน และการย่อขยายตามหน้าจอ - โค้ดยาวกว่า ใช้เวลาพัฒนานานกว่า - เรียนรู้ยาก ต้องเข้าใจ scale, selection และ data join - แผนที่เตรียมข้อมูลเอง เช่น เรียงทิศทางจุดของ polygon ให้ถูกต้อง
Apache ECharts 5	+ กำหนดกราฟด้วย option object เขียนสั้นและพัฒนาได้เร็ว + มี tooltip, legend, แอนิเมชัน, visualMap และการไฮไลต์เมื่อชี้มาให้อัตโนมัติ + ทำแผนที่ได้ทันทีด้วย registerMap และ series แบบ map + เรียนรู้ง่าย มีเอกสารและตัวอย่างจำนวนมาก	- โลใบรารีใหญ่ (~334 KB gzip) - วาดกราฟใหม่ช้ากว่าเมื่อเปลี่ยนตัวกรอง - ปรับแต่งได้เท่าที่ option รองรับ งานนอกกรอบทำได้ยาก - บางอย่างต้องคำนวณเอง เช่น ตำแหน่งของกราฟย่อยหลายช่อง (small multiples) เป็นฟิกเชล

ตารางที่ 2 เปรียบเทียบรายละเอียด


ประเด็น	D3.js v7	ECharts 5	ดีกว่า
จำนวนบรรทัดโค้ดวาดกราฟ (9 กราฟ)	348 บรรทัด	265 บรรทัด	ECharts
ขนาดโลใบรารี (gzip)	~93 KB	~334 KB	D3.js

ประเด็น	D3.js v7	ECharts 5	ดีกว่า
เวลาวาดใหม่เมื่อเปลี่ยนตัวกรอง	~42 ms	~130 ms	D3.js
Tooltip / crosshair	เขียนเองทั้งหมด	มีในตัว ตั้งค่า trigger: "axis"	ECharts
แอนิเมชัน	ต้องเขียนเอง	มีในตัว	ECharts
แผนที่	เขียน projection และ geoPath เอง	registerMap + series แบบ map	ECharts
ความยืดหยุ่นของรูปแบบกราฟ	ไม่จำกัด	อยู่ในขอบเขตของ option	D3.js
ความยากในการเรียนรู้	สูง	ต่ำ	ECharts
เหมาะกับงาน	กราฟเฉพาะทาง งานที่ต้องออกแบบเอง	แดชบอร์ดกราฟมาตรฐานที่ต้องเสร็จเร็ว	—

หน้าเว็บที่สร้างขึ้นโดย D3.js js v7



หน้าเว็บที่สร้างขึ้นโดย Chart.js



5. Data Dictionary

Column	คำอธิบาย	Data Type	นำไปใช้/เหตุผล
State	รัฐของประเทศอินเดีย	Categorical	ใช้เปรียบเทียบพื้นที่
District	เขต/อำเภอภายในรัฐ	Categorical	ใช้วิเคราะห์ระดับพื้นที่
Year	ปีที่รายงานข้อมูล	Numerical	ใช้วิเคราะห์แนวโน้มเวลา
Crime_Type	ประเภทอาชญากรรม	Categorical	ใช้จำแนกประเภท
Cases_Reported	จำนวนคดีที่รายงาน	Numerical	ใช้เป็นตัวแปรวิเคราะห์หลัก
Chargesheeted	จำนวนคดีที่มีการจัดทำเอกสารกล่าวหา	Numerical	ใช้วิเคราะห์กระบวนการดำเนินคดี
Convictions	จำนวนคดีที่มีการพิพากษาว่ามีความผิด	Numerical	ใช้วิเคราะห์ผลลัพธ์ของกระบวนการยุติธรรม
Population	จำนวนประชากรในพื้นที่	Numerical	ใช้เป็นบริบทในการเปรียบเทียบพื้นที่
Crime_Rate_per_100k	อัตราอาชญากรรมต่อประชากร 100,000 คน	Numerical	ใช้วัดระดับอาชญากรรมให้เปรียบเทียบพื้นที่ได้
Justice_index	ดัชนีที่ใช้สะท้อนระดับ/ผลด้านกระบวนการยุติธรรม	Numerical	ใช้ประกอบการจัดกลุ่มและตีความ

6. บันทึกการประชุมกลุ่ม

แผนดำเนินงาน 3 สัปดาห์

ช่วงเวลา	สมาชิก 1	สมาชิก 2	สมาชิก 3	Checkpoint
สัปดาห์ 1 วันที่ 7	ศึกษา dataset	Project Charter/โครงร่างงาน	Wireframe + โครง repo	ส่งหัวข้อ/สมาชิก

สัปดาห์ 1 วันที่ 11-12	Cleaning + Preparation	เขียน Business/Data Understanding	เตรียมโครงเว็บ	Checkpoint 1: raw + cleaned
สัปดาห์ 2 วันที่ 15-16	Modeling + เปรียบเทียบวิธี	เขียน Modeling/Evaluation	เตรียมข้อมูลสำหรับเว็บ	Checkpoint 2: ผลวิเคราะห์
สัปดาห์ 2 วันที่ 18	ตรวจผล/เตรียม insight	ทำสไลด์	พัฒนา D3 + framework 2	Demo เว็บเบื้องต้น
สัปดาห์ 3 วันที่ 21	ตรวจความถูกต้อง	รวม c รายงาน	Interactivity + Responsive	เว็บ 2 เวอร์ชันสมบูรณ์
สัปดาห์ 3 วันที่ 23-24	ตรวจ final	Contribution + README	Deploy GitHub Pages	Live URL + เอกสาร
สัปดาห์ 3 วันที่ 27-28	ซ่อมตอบคำถาม	นำเสนอ	Demo เว็บไซต์	ส่งงาน/นำเสนอ

7. ปัญหาที่พบและวิธีแก้ไข

ปัญหา	ผลกระทบ	วิธีแก้ไข
ข้อมูลมีหลายชนิดและหลายหน่วย	อาจทำให้การจัดกลุ่มถูกรบกวนด้วยตัวแปรที่มีค่าขนาดใหญ่	แยกตัวแปร Categorical/Numerical ออกจากกัน แล้วทำ Standardization ก่อนเข้า K-means
ไม่พบ Missing values หรือข้อมูลซ้ำ	อาจเข้าใจผิดว่าต้องแก้ไขข้อมูลทั้งที่ไม่มีจุดให้ลบหรือเติมค่า	เก็บหลักฐานผลตรวจสอบที่ได้ 0 ค่าไว้ และไม่แก้ไขข้อมูลโดยไม่จำเป็น
การเลือกจำนวนกลุ่ม K-means	ค่า k แต่ละค่าให้ผลตีความต่างกัน	ทดสอบหลายค่า k แล้วดูจากกราฟ Elbow Method ของ Avg. within-cluster distance เพื่อหาจุดที่เหมาะสม (k = 4)
การทำ Visualization ให้ตรงกับโจทย์	กราฟจำนวนมากอาจทำให้ Dashboard ดูซับซ้อนเกินไป	เลือกกราฟตามคำถามที่ต้องการตอบ และเพิ่มตัวกรองเท่าที่จำเป็น
ความแตกต่างระหว่าง D3.js กับ Plotly.js	แนวทางเขียนโค้ดและระดับการควบคุมไม่เหมือนกัน	แบ่งหน้าที่ให้แต่ละคนลองทั้งสองเครื่องมือ แล้วบันทึกผลการพัฒนาไว้เปรียบเทียบกัน

8. บทเรียนที่ได้รับ (Lessons Learned)

- การทำ Data Understanding
ก่อนวิเคราะห์ช่วยให้เลือกวิธีวิเคราะห์ได้ตรงกับชนิดข้อมูลและลดการใช้ตัวแปรผิดประเภท
- การตรวจสอบ Missing และ Duplicate ต้องมีหลักฐาน แม้ผลจะเป็นศูนย์
เพราะเป็นส่วนหนึ่งของการยืนยันคุณภาพข้อมูล

- K-means ต้องให้ความสำคัญกับการปรับเกล็ดตัวแปรและการเลือกจำนวนกลุ่ม ไม่ควรเลือก k โดยไม่มีเกณฑ์
- การออกแบบ Dashboard ควรเริ่มจากคำถามที่ผู้ใช้งานต้องการตอบ แล้วจึงเลือกชนิดกราฟและ interaction
- การแบ่งงานและบันทึกการประชุมอย่างสม่ำเสมอช่วยให้ตรวจสอบได้ว่าใครรับผิดชอบส่วนใดและงานอยู่ในขั้นตอนไหน

9. Checklist ก่อนส่งรายงาน

- ✓ เติมชื่อสมาชิก รหัสนักศึกษา และบทบาทจริง
- ✓ เติมบันทึกการประชุมอย่างน้อยสัปดาห์ละ 1 ครั้ง พร้อมวันที่และผู้เข้าร่วมจริง
- ✓ แนบภาพ Before-After จากขั้นตอนทำความสะอาด/เตรียมข้อมูลจริง
- ✓ แนบภาพหน้าจอ Dashboard D3.js และ framework ที่สอง
- ✓ ตรวจสอบว่า k , metric และผลการทดลองในรายงานตรงกับโค้ดฉบับที่ส่ง
- ✓ ตรวจสอบคำอธิบายผลว่าเป็นข้อมูลจากชุดข้อมูล ไม่สรุปเกินกว่าที่วิเคราะห์ได้